Fakultas Informatika
School of Computing
Telkom University

Telkom University

CAK4KBB3 GENERATIVE AI MINI TRANSFORMER
(MINI GPT - Decoder Only Transformer)



Kelompok Ayayo Team · IF-47-GAB04

Dosen Dr. Aditya Firman Ihsan, S.Si., M.Si.

Dzaki Alwan Firjatullah · Firdaus Akbar Amrullah

Rafa Suryaputra · Muhammad Raihan Fahrifi



Merancang Sistem, Rencana Tim Bekerja dan Strategi

Tujuan proyek

Membangun

model bahasa generatif berukuran kecil yang dibuat menggunakan PyTorch dan dilatih dari nol menggunakan teks berita berbahasa Indonesia. Model ini termasuk decoder-only Transformer, yaitu arsitektur yang mempelajari cara memprediksi token berikutnya berdasarkan token-token sebelumnya.

Memahami

mekanisme Transformer tanpa modul siap pakai

Menerapkan

arsitektur mini Transformer sebagai proses belajar end-to-end



Pipeline data

1 Perancangan data subset dan streaming downloader

2 Preprocessing, Deduplikasi dan Pembagian data

3 Costum Regex, Determinisme dan Test Leakage

4 Penanganan Token Spesial BOS/EOS, sliding window dan Data Loader

5 Testing integrasi dan pembaruan Dataset Card



Implementasi Komponen Inti Transformer

Sinusoidal Positional Encoding | Query, Key, dan Value (Q, K, V) | Scaled Dot-Product Attention | Causal Masking | Multi-Head Attention | Feed-Forward Network (FFN) | Decoder Block, Pre-LayerNorm, dan Residual Connection

Arsitektur model



↓

Sinusoidal Positional Encoding

Menambahkan informasi posisi token agar model memahami urutannya.

Output: [B, T, 64]

↓

4× Decoder Block (Pre-LayerNorm)

Causal Multi-Head Self-Attention

4 attention head mempelajari hubungan antartoken.

Causal mask mencegah model melihat token masa depan.

↓

Residual Connection + LayerNorm

Mempertahankan aliran informasi dan membantu kestabilan training.

↓

Feed-Forward Network (FFN) + GELU

Mengolah representasi token secara nonlinier.

64 → 256 → 64

Proses ini dilakukan dalam 4 Decoder Block secara berurutan.

↓

Final LayerNorm + Language Modeling Head

Mengubah representasi akhir menjadi skor prediksi untuk setiap token dalam vocabulary.

Logits: [B, T, 16.278]

↓

Prediksi Token Berikutnya

Greedy atau sampling memilih satu token ID untuk ditambahkan ke urutan.

↓

Ulangi prediksi sampai EOS atau batas token baru tercapai.

Post-processing

Token ID → teks → perbaikan spasi, tanda baca, kapitalisasi, dan pemotongan kalimat.

↓

Teks Hasil Generasi

Output akhir yang ditampilkan kepada pengguna.

MiniGPT, Training Loop & Text Generation

1. **MiniGPT (Arsitektur Model Utuh): Mengintegrasikan komponen individual menjadi satu model utuh. Alur datanya: Input Token ID -> Token Embedding + Positional Embedding -> N x Decoder Block -> Pre-LayerNorm -> Linear Head -> Logits. Linear Head memetakan dimensi tersembunyi (hidden dimension) kembali ke ukuran kosakata (vocab size).**
2. **Training Loop (Siklus Pelatihan): Menggunakan mekanisme Causal Language Modeling untuk memprediksi kata berikutnya. Input berupa urutan token x_1, x_2, ..., x_{t-1} dan target berupa token bergeser satu langkah ke depan x_2, x_3, ..., x_t. Loss dihitung menggunakan Cross-Entropy Loss, kemudian gradien dihitung via backpropagation untuk memperbarui bobot model dengan optimizer seperti AdamW.**
3. **Text Generation (Pembangkitan Teks): Menggunakan sifat autoregressive. Model memprediksi satu token, menambahkan token tersebut ke input prompt, lalu memprediksinya kembali secara berulang. Strategi sampling yang umum meliputi Greedy Search, Temperature Sampling, serta Top-k / Top-p (Nucleus) Sampling.**

Beberapa percobaan training dan generate (C14 dulu)



Percobaan pertama ini dibantu dengan tools modal.com. Coba training dengan 4 epoch. Tapi disini masih terjadi kekurangan, adanya indikasi overfitting. Terlihat Train Loss semakin turun (semakin bagus), tetapi validation loss nya malah semakin naik angknya (signifikan). Karena credit kami terbatas, maka kami tinggalkan tools modal.com buat training

{"event": "generation", "prompt": "presiden indonesia", "generated": "presiden indonesia , jokowi mengutus erick thohir bertemu dengan presiden jokowi . jokowi menyebut bahwa pertemuan itu tidak ada campur tangan dengan ppp . \" saya tidak ada pembicaraan formal . saya pikir itu , \" kata dia . saya , saya", "total_seconds": 5304.64, "device": "cpu", "torch_version": "2.5.1+cu121", "vocab_size": 19192, "n_train_segments": 246290, "n_val_segments": 28229, "n_params": 2556672, "history": [{"epoch": 1, "train_loss": 5.568583, "val_loss": 7.13515, "epoch_sec": 1123.65}, {"epoch": 2, "train_loss": 4.152143, "val_loss": 7.856671, "epoch_sec": 921.85}, {"epoch": 3, "train_loss": 3.640476, "val_loss": 8.304918, "epoch_sec": 1115.32}, {"epoch": 4, "train_loss": 3.335589, "val_loss": 8.649888, "epoch_sec": 2120.66}]}

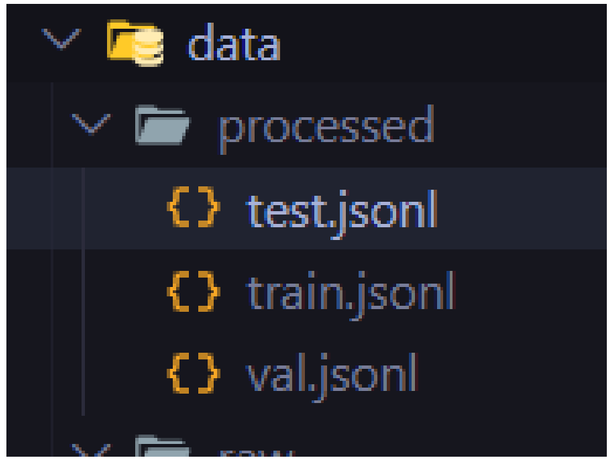
Beberapa percobaan training dan generate (C15 sekarang)


```
{"event": "epoch", "epoch": 1, "train_loss": 8.583913, "val_loss": 6.027056, "
{"event": "epoch", "epoch": 2, "train_loss": 5.609852, "val_loss": 5.537571, "
{"event": "epoch", "epoch": 3, "train_loss": 5.111503, "val_loss": 5.357879, "
{"event": "epoch", "epoch": 4, "train_loss": 4.835542, "val_loss": 5.268706, "
{"event": "epoch", "epoch": 5, "train_loss": 4.657244, "val_loss": 5.207686, "
{"event": "epoch", "epoch": 6, "train_loss": 4.530968, "val_loss": 5.167598, "
{"event": "epoch", "epoch": 7, "train_loss": 4.438071, "val_loss": 5.13654, "v
{"event": "epoch", "epoch": 8, "train_loss": 4.373624, "val_loss": 5.098118, "
{"event": "epoch", "epoch": 9, "train_loss": 4.328216, "val_loss": 5.093841, "
{"event": "epoch", "epoch": 10, "train_loss": 4.293643, "val_loss": 5.060602,
{"event": "epoch", "epoch": 11, "train_loss": 4.264978, "val_loss": 5.042315,
{"event": "epoch", "epoch": 12, "train_loss": 4.240258, "val_loss": 5.044313,
{"event": "epoch", "epoch": 13, "train_loss": 4.219555, "val_loss": 5.036331,
{"event": "epoch", "epoch": 14, "train_loss": 4.202321, "val_loss": 5.028038,
{"event": "epoch", "epoch": 15, "train_loss": 4.189172, "val_loss": 5.032481,
{"event": "epoch", "epoch": 16, "train_loss": 4.178174, "val_loss": 5.045652,
{"event": "epoch", "epoch": 17, "train_loss": 4.168422, "val_loss": 5.034808,
{"event": "epoch", "epoch": 18, "train_loss": 4.160656, "val_loss": 5.034833,
{"event": "epoch", "epoch": 19, "train_loss": 4.155064, "val_loss": 5.033659,
{"event": "epoch", "epoch": 20, "train_loss": 4.149939, "val_loss": 5.031224,
{"event": "final_eval", "best_epoch": 14, "tied_epochs": [8, 9, 10, 11, 12, 13
{"event": "generation", "checkpoint": "/kaggle/working/outputs/metrics/minigpt
```


Ini sekarang dibantu tools kaggle (karena kaggle ada free tier memungkinkan kita untuk training dengan menggunakan CPU/GPU yang oke dan sanggup)

sekarang kita coba naikkan jadi 20 epoch dan beberapa penyesuaian, agar hasil generate nya maksimal

Parameter atau hasil	C14	C15
Data train	720	1.440
Validation	80	159
Test	200	200
Vocabulary	19.192	16.278
`min_freq`	1	2
`context_length`	64	128
`n_layers`	2	4
Weight tying	Tidak	Ya
Parameter model	2.556.672	1.241.856
Training aktual	4 epoch	20 epoch
Lingkungan	Modal CPU 8 core, 16 GB	Kaggle Tesla T4
Validation loss terpilih	Validation meningkat pada run yang tercatat	5,0280 pada epoch 14
Test loss per dokumen tanpa UNK	Tidak dibandingkan langsung tanpa menyamakan protokol	5,0091



Data train, validasi, test kita naikkan, parameter model kita turunkan

```
[C15] train: 1440 artikel, 3,295,207 karakter
[C15] val  :  159 artikel,   419,896 karakter
[C15] test :  200 artikel,   447,272 karakter
```

```
PS D:\Kuliah-Ekstensi\Semester_3\Tubes-GenAI\AyayoTeam_MiniTransformer> python tools/generate_text.py
Prompt: Presiden Indonesia

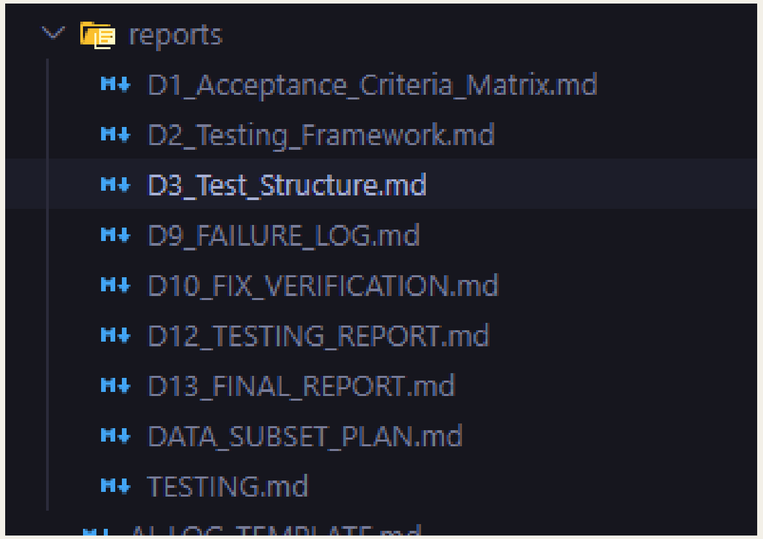
Republik China, pada Maret 2023, Presiden Joko Widodo sempat dari Anas buatan Jokowi. Oleh sebab pelajaran yang ar
tinya ketika menyambut 10, ' Emirat Arab Jokowi di leher sukses saja demi menjaga Pilpres mendatang.
PS D:\Kuliah-Ekstensi\Semester_3\Tubes-GenAI\AyayoTeam_MiniTransformer> python tools/generate_text.py
Prompt: Suara.com

, Tri Prasetyo Adi usulkan adanya satu kursi yang memiliki berkas dari tahap pembelian dan harus membayar 100 prog
ram alias minimal dalam satu mahasiswa, ucapnya. Jika melewati proses verifikasi, akan memenuhi 7 calon peserta la
gi program terpenuhi.
PS D:\Kuliah-Ekstensi\Semester_3\Tubes-GenAI\AyayoTeam_MiniTransformer> python tools/generate_text.py
Prompt: nasional

2023. Dia meyakini pemerintah yang belum tahu bagaimana apa, dari uu larangan dan harus membayar penugasan kepada
pribadi pada Undang - Undang, ' eselon ii kita di Komisi xi dpr ri, berdarah Puan lagi Pak Komisi informasi anggot
a Komisi ii dpr.
PS D:\Kuliah-Ekstensi\Semester_3\Tubes-GenAI\AyayoTeam_MiniTransformer>
```

Testing & Beberapa Laporan

```
PS D:\Kuliah-Ekstensi\Semester_3\Tubes-GenAI\AyayoTeam_MiniTransformer> python -m pytest -q
.....................................................................................sssssss..... [ 54%]
.s.........ssssssss.....................................................................s..... [100%]
=================================================== short test summary info ===================================================
SKIPPED [7] tests\test_end_to_end_pipeline.py: integration tests require --run-integration
SKIPPED [1] tests\test_generate_decoding.py:265: CUDA tidak tersedia
SKIPPED [7] tests\test_integration_components.py: integration tests require --run-integration
SKIPPED [1] tests\test_train_integration.py: integration tests require --run-integration
221 passed, 16 skipped in 23.66s
PS D:\Kuliah-Ekstensi\Semester_3\Tubes-GenAI\AyayoTeam_MiniTransformer>
```



Bisa diliat hasil dari Issue D pada folder docs/reports/..

```
PS D:\Kuliah-Ekstensi\Semester_3\Tubes-GenAI\AyayoTeam_MiniTransformer> python -m pytest -q --run-integration
.....................................................................................................s..................................... [ 70%]
.....................................................                                                                                        [100%]
============================================================ short test summary info ============================================================
SKIPPED [1] tests\test_generate_decoding.py:265: CUDA tidak tersedia
236 passed, 1 skipped in 18.66s
```

menjalankan seluruh test, termasuk test integrasi.

Test integrasi diperlukan untuk memeriksa apakah beberapa komponen dapat bekerja bersama, misalnya:

1. **Dataset dan DataLoader terhubung dengan model.**
2. **Training step benar-benar memperbarui parameter.**
3. **Checkpoint dapat dimuat kembali.**
4. **Model dapat menghasilkan token.**
5. **Pipeline dari input sampai generasi teks dapat berjalan.**

Ada Beberapa perintah test yang dilakukan pada project ini

Perintah 1 · Test standar

`python -m pytest -q`

221 passed · 16 skipped

Test standar dijalankan; test integrasi dilewati.

Perintah 2 · Semua test

`python -m pytest -q --run-integration`

236 passed · 1 skipped

Mencakup test standar dan integrasi.

Perintah 3 · Test integrasi saja

`python -m pytest -q -m integration --run-integration`

15 passed · 222 deselected

Hanya kelompok test integrasi yang dijalankan.

Perintah 4 · Mengumpulkan test

`python -m pytest --collect-only -q --run-integration`

237 tests collected

Menghitung test yang ditemukan tanpa menjalankannya.

Kesimpulan & langkah berikutnya

BERHASIL

Model mini Transformer terlatih dan mampu menghasilkan teks Bahasa Indonesia.

TERBATAS

Kualitas bahasa belum layak menjadi berita faktual; ukuran model, data, dan tokenisasi membatasi hasil.

BERIKUTNYA

Perbesar dataset, perbaiki arsitektur dan tokenisasi, lalu optimalkan proses training.


TERIMA KASIH